Sinh chú thích ảnh tiếng Việt trên KTVIC

Nguyễn Đức Minh (24022405) **Đoàn Quang Mạnh (24022339)**
Nhóm 10 – Đề tài 05 – Môn Học sâu

Tóm tắt

Nhóm nghiên cứu bài toán sinh chú thích ảnh tiếng Việt trên bộ dữ liệu KTVIC. Hai hướng tiếp cận chính là CNN kết hợp LSTM có attention và CNN kết hợp Transformer decoder. Các mô hình được so sánh trên cùng cách chia dữ liệu, tiền xử lý và chỉ số BLEU, CIDEr, kèm phân tích lỗi của câu mô tả.

1 Bài toán và mục tiêu

Đầu vào là một ảnh RGB; đầu ra là một câu mô tả nội dung chính bằng tiếng Việt. Mục tiêu là xây dựng hệ thống chú thích ảnh và so sánh chất lượng sinh câu của LSTM có attention với Transformer decoder khi dùng chung CNN encoder và dữ liệu huấn luyện.

2 Dữ liệu và tiền xử lý

Nhóm chọn KTVIC, bộ dữ liệu mô tả ảnh tiếng Việt thuộc miền đời sống (Pham et al., 2024). Bản dữ liệu local có 3.769 ảnh official train, mỗi ảnh năm chú thích. Sử dụng split hiện có với seed 42: 3.202 ảnh train, 565 validation và 558 official test; hai bản ảnh phía train trùng byte với test đã được cách ly. Các chú thích của một ảnh luôn thuộc cùng một tập.



Hình 1: Mẫu ảnh train KTVIC, ID 4. Hai trong năm chú thích gốc: "người phụ nữ đang nhìn vào những chiếc đèn lồng"; "người phụ nữ đang ngắm những chiếc đèn lồng ở trước mặt". Đây là nhãn dữ liệu, không phải câu do mô hình sinh.

Ảnh được chuyển RGB, chuẩn hóa theo encoder và đưa về 224×224. Văn bản dùng `segment_caption`, chuẩn Unicode NFC, chữ thường và giữ dấu gạch dưới của từ đã tách. Vocabulary chỉ xây trên train; thêm token bắt đầu, kết thúc, đệm và từ ngoài từ vựng. Audit dữ liệu hiện có ghi nhận 13 ảnh validation gần trùng train; hạn chế này được lưu ý khi diễn giải kết quả.

3 Baseline và phương pháp dự kiến

Baseline CNN–LSTM: CNN trích xuất đặc trưng ảnh toàn cục, LSTM sinh câu từng token, theo hướng encoder–decoder của Vinyals et al. (2015). Đây là baseline tham chiếu, không thay thế mô hình có attention theo yêu cầu đề bài.

CNN–LSTM có attention: ResNet50 tiền huấn luyện giữ lưới đặc trưng 7×7; LSTM dùng additive soft attention để tổng hợp vùng ảnh ở từng bước sinh, theo hướng Xu et al. (2015).

CNN–Transformer: dùng cùng CNN encoder; Transformer decoder gồm masked self-attention trên chuỗi token và cross-attention vào đặc trưng ảnh (Vaswani et al., 2017).

Encoder được đóng băng trong so sánh chính. Decoder được huấn luyện bằng teacher forcing và cross-entropy bỏ qua token đệm. Cấu hình khởi đầu dùng batch 32, tối đa 25 epochs và dừng sớm theo CIDEr validation; lưu siêu tham số, seed và log để tái lập.

4 Cách đánh giá

Đánh giá bằng BLEU-1/2/3/4 và CIDEr ở mức corpus với đủ năm chú thích tham chiếu mỗi ảnh. Giữ chung split, tokenizer và quy tắc chấm điểm; chọn checkpoint và cách giải mã trên validation, khóa cấu hình trước khi đánh giá test. Bổ sung so sánh có/không có attention, ví dụ sinh câu tốt và sai, lỗi đối tượng, hành động và quan hệ trong ảnh. Không dùng test để tinh chỉnh mô hình.

5 Kế hoạch sáu tuần

Tuần	Công việc và mốc bàn giao
1	Đọc tài liệu, dữ liệu, môi trường; proposal.
2	Baseline, kiểm tra pipeline, log huấn luyện.
3	LSTM attention, Transformer; milestone.
4	So sánh, ablation, tinh chỉnh trên validation.
5	Mở rộng, phân tích lỗi; nháp báo cáo.
6	Báo cáo ACL, mã nguồn, slide và demo.

Phân công dự kiến: Nguyễn Đức Minh phụ trách dữ liệu, tokenizer, CNN và LSTM attention. Đoàn Quang Mạnh phụ trách Transformer, bộ đánh giá và so sánh thí nghiệm. Cả hai cùng rà mã, phân tích lỗi, viết báo cáo và chuẩn bị thuyết trình.
Khai báo công cụ: AI hỗ trợ chuẩn bị mã, kiểm tra và soạn thảo; nhóm chịu trách nhiệm kiểm chứng nội dung.

References

Anh-Cuong Pham, Van-Quang Nguyen, Thi-Hong Vuong, and Quang-Thuy Ha. 2024. Ktvic: A vietnamese image captioning dataset on the life domain. *arXiv preprint arXiv:2401.08100*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*.

Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. 2015. Show and tell: A neural image caption generator. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3156–3164.

Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhudinov, Rich Zemel, and Yoshua Bengio. 2015. Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 2048–2057.