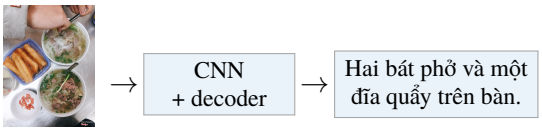
Sinh chú thích ảnh tiếng Việt trên KTVIC

Nguyễn Đức Minh (24022405) **Đoàn Quang Mạnh (24022339)**
Nhóm 10 – Đề tài 05 – Môn Học sâu

1 Bài toán và mục tiêu

Đầu vào là một ảnh RGB; đầu ra là một câu mô tả tiếng Việt. Nhóm so sánh LSTM có attention với Transformer decoder khi dùng chung CNN encoder và dữ liệu huấn luyện.



Ảnh RGB

Đầu vào → mô hình → câu tiếng Việt.
Câu bên phải minh họa đầu ra mong muốn.

2 Dữ liệu và tiền xử lý

Nhóm chọn KTVIC, gồm 4.327 ảnh và 21.635 chú thích tiếng Việt do con người gán nhãn, thuộc miền đời sống (Pham et al., 2024). Mỗi ảnh có năm cặp `caption` và `segment_caption`; Hình 1 minh họa cấu trúc này.

Lý do lựa chọn. UIT-ViIC tập trung vào thể thao với bóng (Lam et al., 2020), còn KTVIC phù hợp mục tiêu mô tả đời sống thường ngày. So với tự dịch MS-COCO, nhãn tiếng Việt và bản tách từ sẵn có giúp giảm công dịch và kiểm tra sai lệch nghĩa. Nhóm chọn KTVIC theo phạm vi sáu tuần và nguồn lực hai người, không coi đây là bộ dữ liệu tốt nhất cho mọi bài toán.

Các bước tiền xử lý

- **Chia dữ liệu:** kiểm tra trùng ảnh → cách ly 2 ảnh train trùng byte với test → chia theo ảnh, seed 42: train 3.202, validation 565, test 558 ảnh. Các chú thích của một ảnh luôn cùng tập.
- **Ảnh:** RGB → resize/crop 224×224 → chuẩn hóa → tensor $3 \times 224 \times 224$.
- **Văn bản:** `segment_caption` → Unicode NFC → chữ thường → tách token, giữ dấu gạch dưới.
- **Mã hóa:** xây vocabulary chỉ từ train → thêm BOS/EOS/PAD/UNK → token IDs và padding mask; dùng cố định cho validation/test.

Lưu ý: audit ghi nhận 13 ảnh validation gần trùng train; cần công bố khi diễn giải kết quả.

3 Baseline và phương pháp dự kiến

Baseline CNN–LSTM: CNN trích xuất vector ảnh toàn cục, LSTM sinh từng token, theo hướng Vinyals et al. (2015).

CNN–LSTM có attention: ResNet50 tiền huấn luyện giữ lưới đặc trưng 7×7; LSTM dùng additive soft attention để tổng hợp vùng ảnh ở từng bước sinh, theo hướng Xu et al. (2015).

CNN–Transformer: dùng cùng CNN encoder; Transformer decoder gồm masked self-attention trên chuỗi token và cross-attention vào đặc trưng ảnh (Vaswani et al., 2017).

Đóng băng encoder; huấn luyện decoder bằng teacher forcing và cross-entropy bỏ PAD. Khởi đầu batch 32, tối đa 25 epochs, dừng sớm theo CIDEr validation; lưu cấu hình và log.

Phần mở rộng: sau hai mô hình bắt buộc, ưu tiên thay ResNet50 bằng encoder ảnh CLIP, giữ decoder và quy trình đánh giá để so sánh. Nếu đủ thời gian, tìm ảnh theo tương đồng ngữ nghĩa giữa truy vấn tiếng Việt và caption sinh.

4 Cách đánh giá

- **Chọn mô hình:** đánh giá trên validation → chọn checkpoint và cách giải mã → khóa cấu hình.
- **Chấm test:** ảnh test → mô hình đã chọn → câu dự đoán → đối chiếu đủ 5 chú thích tham chiếu mỗi ảnh → BLEU-1/2/3/4 và CIDEr ở mức corpus.



image_id: 10954

"caption": "có hai tô phở cùng một đĩa quẩy xuất hiện ở trên bàn"
"segment_caption": "có hai tô phở cùng một đĩa quẩy xuất_hiện ở trên bàn"

"caption": "có một người đang cầm trên tay một cái thìa"
"segment_caption": "có một người đang cầm trên tay một cái thìa"

"caption": "có một cái muỗng xuất hiện ở trên tay của một người"
"segment_caption": "có một cái muỗng xuất_hiện ở trên tay của một người"

"caption": "có một đĩa quẩy được đặt ở bên cạnh hai bát phở"
"segment_caption": "có một đĩa quẩy được đặt ở bên cạnh hai bát phở"

"caption": "có hai bát phở được bày ra ở trên bàn"
"segment_caption": "có hai bát phở được bày ra ở trên bàn"

Năm chú thích gốc và phiên bản tách từ

Hình 1: Ví dụ một mẫu ảnh và nhãn trong KTVIC: ảnh ID 10954 và đủ năm cặp chú thích.

- **So sánh:** cùng split, tokenizer và cách chấm → so sánh decoder, có/không attention → phân tích lỗi đối tượng, hành động, quan hệ.

Không dùng test để tinh chỉnh mô hình.

5 Phân công dự kiến

- **Nguyễn Đức Minh:** dữ liệu, tokenizer, CNN và LSTM attention.
- **Đoàn Quang Mạnh:** Transformer, bộ đánh giá và so sánh thí nghiệm.
- **Cả hai:** rà mã, phân tích lỗi, viết báo cáo và chuẩn bị thuyết trình.

References

Quan Hoang Lam, Quang Duy Le, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2020. UIT-ViIC: A dataset for the first evaluation on vietnamese image captioning. *arXiv preprint arXiv:2002.00175*.

Anh-Cuong Pham, Van-Quang Nguyen, Thi-Hong Vuong, and Quang-Thuy Ha. 2024. Ktvic: A vietnamese image captioning dataset on the life domain. *arXiv preprint arXiv:2401.08100*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*.

Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. 2015. Show and tell: A neural image caption generator. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3156–3164.

Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhudinov, Rich Zemel, and Yoshua Bengio. 2015. Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 2048–2057.