Sinh chú thích ảnh tiếng Việt trên KTVIC

Nguyễn Đức Minh (24022405) **Đoàn Quang Mạnh (24022339)**
Nhóm 10 – Đề tài 05 – Môn Học sâu

Tóm tắt

Nhóm nghiên cứu bài toán sinh chú thích ảnh tiếng Việt trên bộ dữ liệu KTVIC. Hai hướng tiếp cận chính là CNN kết hợp LSTM có attention và CNN kết hợp Transformer decoder. Các mô hình được so sánh trên cùng cách chia dữ liệu, tiền xử lý và chỉ số BLEU, CIDEr, kèm phân tích lỗi của câu mô tả.

1 Bài toán và mục tiêu

Đầu vào là một ảnh RGB; đầu ra là một câu mô tả nội dung chính bằng tiếng Việt. Mục tiêu là xây dựng hệ thống chú thích ảnh và so sánh chất lượng sinh câu của LSTM có attention với Transformer decoder khi dùng chung CNN encoder và dữ liệu huấn luyện.

2 Dữ liệu và tiền xử lý

Nhóm chọn KTVIC, gồm 4.327 ảnh và 21.635 chú thích tiếng Việt do con người gán nhãn, thuộc miền đời sống (Pham et al., 2024). Mỗi ảnh có năm cặp `caption` và `segment_caption`; Hình 1 minh họa cấu trúc này.

Lý do lựa chọn. So với UIT-ViIC, vốn tập trung vào các môn thể thao với bóng (Lam et al., 2020), miền đời sống của KTVIC phù hợp hơn với mục tiêu mô tả hoạt động thường ngày. So với phương án tự dịch MS-COCO sang tiếng Việt, KTVIC có sẵn nhãn tiếng Việt và bản tách từ, giúp nhóm hai người giảm công dịch và kiểm tra sai lệch nghĩa. Quy mô này cũng phù hợp với phạm vi thí nghiệm sáu tuần của nhóm. Đây là lựa chọn theo mục tiêu và nguồn lực, không khẳng định KTVIC tốt hơn mọi bộ dữ liệu.

Sử dụng split hiện có với seed 42: 3.202 ảnh train, 565 validation và 558 test; hai ảnh phía train trùng byte với test đã được cách ly. Mọi chú thích của một ảnh thuộc cùng một tập.

Ảnh được chuyển RGB, chuẩn hóa theo encoder và đưa về 224×224. Văn bản dùng `segment_caption`, chuẩn Unicode NFC, chữ thường và giữ dấu gạch dưới của từ đã tách. Vocabulary chỉ xây trên train; thêm token bắt đầu, kết thúc, đệm và từ ngoài từ vựng. Audit dữ liệu hiện có ghi nhận 13 ảnh validation gần trùng train; hạn chế này được lưu ý khi diễn giải kết quả.

3 Baseline và phương pháp dự kiến

Baseline CNN–LSTM: CNN trích xuất đặc trưng ảnh toàn cục, LSTM sinh câu từng token, theo hướng encoder–decoder của Vinyals et al. (2015). Đây là baseline tham chiếu, không thay thế mô hình có attention theo yêu cầu đề bài.

CNN–LSTM có attention: ResNet50 tiền huấn luyện giữ lưới đặc trưng 7×7; LSTM dùng additive soft attention để tổng hợp vùng ảnh ở từng bước sinh, theo hướng Xu et al. (2015).

CNN–Transformer: dùng cùng CNN encoder; Transformer decoder gồm masked self-attention trên chuỗi token và cross-attention vào đặc trưng ảnh (Vaswani et al., 2017).

Encoder được đóng băng trong so sánh chính. Decoder được huấn luyện bằng teacher forcing và cross-entropy bỏ qua token đệm. Cấu hình khởi đầu dùng batch 32, tối đa 25 epochs và dừng sớm theo CIDEr validation; lưu siêu tham số, seed và log để tái lập.

4 Cách đánh giá

Đánh giá bằng BLEU-1/2/3/4 và CIDEr ở mức corpus với đủ năm chú thích tham chiếu mỗi ảnh. Giữ chung split, tokenizer và quy tắc chấm điểm; chọn checkpoint và cách giải mã trên validation, khóa cấu hình trước khi đánh giá test. Bổ sung so sánh có/không có attention, ví dụ sinh câu tốt và sai, lỗi đối tượng, hành động và quan hệ trong ảnh. Không dùng test để tinh chỉnh mô hình.



image_id: 10954

"caption": “có hai tô phở cùng một đĩa quẩy xuất hiện ở trên bàn”
"segment_caption": “có hai tô phở cùng một đĩa quẩy xuất_hiện ở trên bàn”

"caption": “có một người đang cầm trên tay một cái thìa”
"segment_caption": “có một người đang cầm trên tay một cái thìa”

"caption": “có một cái muỗng xuất hiện ở trên tay của một người”
"segment_caption": “có một cái muỗng xuất_hiện ở trên tay của một người”

"caption": “có một đĩa quẩy được đặt ở bên cạnh hai bát phở”
"segment_caption": “có một đĩa quẩy được đặt ở bên cạnh hai bát phở”

"caption": “có hai bát phở được bày ra ở trên bàn”
"segment_caption": “có hai bát phở được bày ra ở trên bàn”

Năm chú thích gốc và phiên bản tách từ

Hình 1: Ví dụ gán nhãn trong KTVIC: ảnh ID 10954 và đủ năm cặp chú thích. Dấu gạch dưới nối các âm tiết thuộc cùng một từ, như `xuất_hiện`. Dựng lại từ ảnh và annotation gốc, theo bố cục Hình 1 của Pham et al. (2024); không phải kết quả mô hình sinh.

5 Kế hoạch sáu tuần

Tuần	Công việc và mốc bàn giao
1	Đọc tài liệu, dữ liệu, môi trường; proposal.
2	Baseline, kiểm tra pipeline, log huấn luyện.
3	LSTM attention, Transformer; milestone.
4	So sánh, ablation, tinh chỉnh trên validation.
5	Mở rộng, phân tích lỗi; nháp báo cáo.
6	Báo cáo ACL, mã nguồn, slide và demo.

Phân công dự kiến: Nguyễn Đức Minh phụ trách dữ liệu, tokenizer, CNN và LSTM attention. Đoàn Quang Mạnh phụ trách Transformer, bộ đánh giá và so sánh thí nghiệm. Cả hai cùng rà mã, phân tích lỗi, viết báo cáo và chuẩn bị thuyết trình.
Khai báo công cụ: AI hỗ trợ chuẩn bị mã, kiểm tra và soạn thảo; nhóm chịu trách nhiệm kiểm chứng nội dung.

References

Quan Hoang Lam, Quang Duy Le, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2020. UIT-ViIC: A dataset for the first evaluation on vietnamese image captioning. *arXiv preprint arXiv:2002.00175*.

Anh-Cuong Pham, Van-Quang Nguyen, Thi-Hong Vuong, and Quang-Thuy Ha. 2024. Ktvic: A vietnamese image captioning dataset on the life domain. *arXiv preprint arXiv:2401.08100*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*.

Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. 2015. Show and tell: A neural image caption generator. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3156–3164.

Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhudinov, Rich Zemel, and Yoshua Bengio. 2015. Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 2048–2057.