Sinh chú thích ảnh tiếng Việt trên KTVIC

Nguyễn Đức Minh (24022405) **Đoàn Quang Mạnh (24022339)**
Nhóm 10 – Đề tài 05 – Môn Học sâu

1 Bài toán và mục tiêu

Đầu vào là một ảnh RGB; đầu ra là một câu mô tả tiếng Việt. Nhóm so sánh LSTM có attention với Transformer decoder khi dùng chung CNN encoder và dữ liệu huấn luyện.



Ảnh RGB

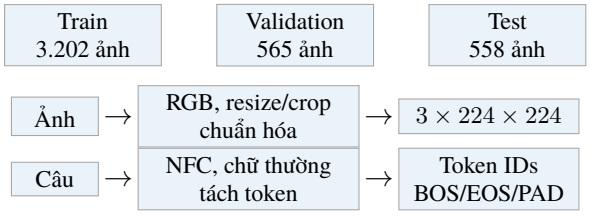
Đầu vào → mô hình → câu tiếng Việt.
Câu bên phải minh họa đầu ra mong muốn.

2 Dữ liệu và tiền xử lý

Nhóm chọn KTVIC, gồm 4.327 ảnh và 21.635 chú thích tiếng Việt do con người gán nhãn, thuộc miền đời sống (Pham et al., 2024). Mỗi ảnh có năm cặp `caption` và `segment_caption`; Hình 1 minh họa cấu trúc này.

Lý do lựa chọn. UIT-ViIC tập trung vào thể thao với bóng (Lam et al., 2020), còn KTVIC phù hợp mục tiêu mô tả đời sống thường ngày. So với tự dịch MS-COCO, nhãn tiếng Việt và bản tách từ sẵn có giúp giảm công dịch và kiểm tra sai lệch nghĩa. Nhóm chọn KTVIC theo phạm vi sáu tuần và nguồn lực hai người, không coi đây là bộ dữ liệu tốt nhất cho mọi bài toán.

Chia theo ảnh với seed 42; mọi chú thích của một ảnh thuộc cùng một tập. Hai ảnh phía train trùng byte với test đã được cách ly.



Văn bản dùng `segment_caption`, giữ dấu gạch dưới của từ đã tách. Vocabulary chỉ xây trên train, thêm BOS/EOS/PAD/UNK. Audit ghi nhận 13 ảnh validation gần trùng train; cần lưu ý khi diễn giải kết quả.

3 Baseline và phương pháp dự kiến

Baseline CNN–LSTM: CNN trích xuất vector ảnh toàn cục, LSTM sinh từng token, theo hướng Vinyals et al. (2015).

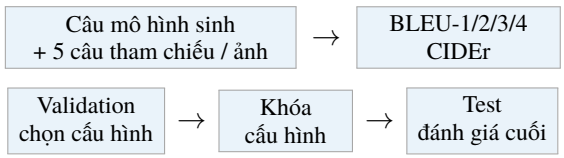
CNN–LSTM có attention: ResNet50 tiền huấn luyện giữ lưới đặc trưng 7×7; LSTM dùng additive soft attention để tổng hợp vùng ảnh ở từng bước sinh, theo hướng Xu et al. (2015).

CNN–Transformer: dùng cùng CNN encoder; Transformer decoder gồm masked self-attention trên chuỗi token và cross-attention vào đặc trưng ảnh (Vaswani et al., 2017).

Đóng băng encoder; huấn luyện decoder bằng teacher forcing và cross-entropy bỏ PAD. Khởi đầu batch 32, tối đa 25 epochs, dừng sớm theo CIDEr validation; lưu cấu hình và log.

Phần mở rộng: sau khi hoàn thành hai mô hình bắt buộc, ưu tiên thay ResNet50 bằng image encoder của CLIP, giữ chung decoder và quy trình đánh giá để khảo sát ảnh hưởng của encoder. Nếu còn thời gian, xây ứng dụng tìm ảnh bằng câu tiếng Việt: sinh chú thích cho kho ảnh, rồi xếp hạng ảnh theo độ tương đồng ngữ nghĩa giữa truy vấn và chú thích. Minh phụ trách encoder, Mạnh phụ trách tìm kiếm và demo.

4 Cách đánh giá



Chấm BLEU-1/2/3/4 và CIDEr ở mức corpus, dùng đủ năm references mỗi ảnh và chung tokenizer. Chọn checkpoint/cách giải mã trên validation, khóa cấu hình trước test; không dùng test để tinh chỉnh. Bổ sung so sánh có/không attention và phân tích lỗi đối tượng, hành động, quan hệ.



image_id: 10954

"caption": "có hai tô phở cùng một đĩa quẩy xuất hiện ở trên bàn"
"segment_caption": "có hai tô phở cùng một đĩa quẩy xuất_hiện ở trên bàn"

"caption": "có một người đang cầm trên tay một cái thìa"
"segment_caption": "có một người đang cầm trên tay một cái thìa"

"caption": "có một cái muỗng xuất hiện ở trên tay của một người"
"segment_caption": "có một cái muỗng xuất_hiện ở trên tay của một người"

"caption": "có một đĩa quẩy được đặt ở bên cạnh hai bát phở"
"segment_caption": "có một đĩa quẩy được đặt ở bên cạnh hai bát phở"

"caption": "có hai bát phở được bày ra ở trên bàn"
"segment_caption": "có hai bát phở được bày ra ở trên bàn"

Năm chú thích gốc và phiên bản tách từ

Hình 1: Ví dụ gán nhãn trong KTVIC: ảnh ID 10954 và đủ năm cặp chú thích. Dấu gạch dưới nối các âm tiết thuộc cùng một từ, như `xuất_hiện`. Dựng lại từ ảnh và annotation gốc, theo bố cục Hình 1 của Pham et al. (2024); không phải kết quả mô hình sinh.

5 Kế hoạch sáu tuần

Tuần	Công việc và mốc bàn giao
1	Đọc tài liệu, dữ liệu, môi trường; proposal.
2	Baseline, kiểm tra pipeline, log huấn luyện.
3	LSTM attention, Transformer; milestone.
4	So sánh, ablation, tinh chỉnh trên validation.
5	Thử CLIP; tìm ảnh nếu đủ thời gian; nháp.
6	Báo cáo ACL, mã nguồn, slide và demo.

Phân công dự kiến

- **Nguyễn Đức Minh:** dữ liệu, tokenizer, CNN và LSTM attention.
- **Đoàn Quang Mạnh:** Transformer, bộ đánh giá và so sánh thí nghiệm.
- **Cả hai:** rà mã, phân tích lỗi, viết báo cáo và chuẩn bị thuyết trình.

Khai báo công cụ: AI hỗ trợ chuẩn bị mã, kiểm tra và soạn thảo; nhóm chịu trách nhiệm kiểm chứng nội dung.

References

Quan Hoang Lam, Quang Duy Le, Kiet Van Nguyen, and Ngan Luu-Thuy Nguyen. 2020. UIT-ViIC: A dataset for the first evaluation on vietnamese image captioning. *arXiv preprint arXiv:2002.00175*.

Anh-Cuong Pham, Van-Quang Nguyen, Thi-Hong Vuong, and Quang-Thuy Ha. 2024. Ktvic: A vietnamese image captioning dataset on the life domain. *arXiv preprint arXiv:2401.08100*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*.

Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. 2015. Show and tell: A neural image caption generator. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3156–3164.

Kelvin Xu, Jimmy Ba, Ryan Kiros, Kyunghyun Cho, Aaron Courville, Ruslan Salakhudinov, Rich Zemel, and Yoshua Bengio. 2015. Show, attend and tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pages 2048–2057.